

Analiza Sephora proizvoda i njihovih recenzija

Marija Todorović IN 13/2022
Nenad Lukić IN 17/2022





Skup podataka

Tema:

Analiza kozmetičkih proizvoda i ponašanja korisnika na Sephora platformi kroz napredne MongoDB upite za optimizaciju tržišnih trendova i personalizaciju preporuka.

Datoteke:

Postoji 6 datoteka grupisanih na 2 kategorije:

- Prva sadrži informacije o svim kozmetičkim proizvodima iz Sephora onlajn prodavnice, uključujući nazive proizvoda i brendova, cene, sastojke, ocene i sve karakteristike.
- Druga sadrži recenzije korisnika (oko 1 milion za više od 2.000 proizvoda) za sve proizvode iz kategorije nege kože (Skincare), uključujući fizičke karakteristike korisnika i ocene tih recenzija od strane drugih korisnika.

Link ka skupu podataka:

<https://www.kaggle.com/datasets/nadyinky/sephora-products-and-skincare-reviews>



Skup podataka

Broj zapisa:

- 8.496 zapisa unutar datoteke `product_info`.
- 1.107.415 zapisa kroz svih 5 reviews datoteka.

Objašnjene kolone za `product_info`:

- `product_id`: Jedinstveni identifikator proizvoda sa sajta.
- `product_name`: Pun naziv proizvoda.
- `brand_id`: Jedinstveni identifikator brenda čiji je proizvod.
- `brand_name`: Pun naziv brenda koji je napravio proizvod.
- `loves_count`: Broj ljudi koji su označili ovaj proizvod kao omiljeni.
- `rating`: Prosečna ocena proizvoda zasnovana na korisničkim recenzijama.
- `reviews`: Broj recenzija korisnika za sam proizvod.
- `size`: Veličina proizvoda, može biti zapisano u više metričkih jedinica, u zavisnosti od tipa proizvoda.
- `variation_type`: Tip parametra varijacije za proizvod (npr. *Size*, *Color*).
- `variation_value`: Specifična vrednost parametra varijacije proizvoda (npr. *100 mL*, *Golden Sand*).
- `variation_desc`: Opis parametra varijacije (npr. *tone for fairest skin*).
- `price_usd`: Cena proizvoda u američkim dolarima.



Skup podataka

Objašnjene kolone za `product_info`:

- `ingredients`: Lista sastojaka koji se nalaze u proizvodu (npr. [*'Product variation 1:', 'Water, Glycerin', 'Product variation 2:', 'Talc, Mica']* or if no variations [*'Water, Glycerin'*]).
- `value_price_usd`: Moguća ušteda po proizvodu, na sajtu prikazana pored regularne cene.
- `sale_price_usd`: Cena tokom rasprodaje proizvoda u američkim dolarima.
- `limited_edition`: *Boolean* indikator da li proizvod pripada ograničenoj kolekciji ili ne.
- `new`: *Boolean* indikator da li je proizvod nov ili ne.
- `online_only`: *Boolean* indikator da li se proizvod prodaje samo onlajn ili ne.
- `out_of_stock`: *Boolean* indikator da li je proizvod trenutno nedostupan ili dostupan.
- `sephora_exclusive`: *Boolean* indikator da li je proizvod ekskluzivan za Sephora ili ne.
- `highlights`: Lista tagova i osobina koje označavaju atribut (npr. [*'Vegan', 'Matte Finish'*]).
- `primary_category`: Prva kategorija navedena u *breadcrumb* sekciji.
- `secondary_category`: Druga kategorija navedena u *breadcrumb* sekciji.
- `tertiary_category`: Treća kategorija navedena u *breadcrumb* sekciji.
- `child_count`: Broj dostupnih varijacija proizvoda.
- `child_max_price`: Najveća cena među varijacijama proizvoda.
- `child_min_price`: Najmanja cena među varijacijama proizvoda.



Skup podataka

Objašnjene kolone za reviews:

- *author_id*: Jedinstveni identifikator autora koji je ostao recenziju na sajtu.
- *rating*: Ocena koju je korisnik dao proizvodu na skali od 1 do 5.
- *is_recommended*: *Boolean* indikator da li autor preporučuje proizvod ili ne.
- *helpfulness*: Odnos svih pozitivnih i negativnih ocena za recenziju:
 $helpfulness = total_pos_feedback_count + total_feedback_count$.
- *total_feedback_count*: Ukupan broj ocena ostavljenih od strane korisnika za recenziju.
- *total_neg_feedback_count*: Ukupan broj negativnih ocena od strane korisnika za recenziju.
- *total_pos_feedback_count*: Ukupan broj pozitivnih ocena od strane korisnika za recenziju.
- *submission_time*: Datum kad je recenzija postavljena, u "yyyy-mm-dd" formatu.
- *review_text*: Glavni tekst same recenzije.
- *review_title*: Naslov same recenzije.
- *skin_tone*: Ton kože autora recenzije (npr. *fair*, *tan*...).
- *eye_color*: Boja očiju autora recenzije (npr. *brown*, *green*...).
- *skin_type*: Tip kože autora recenzije (npr. *combination*, *oily*...).
- *hair_color*: Boja kose autora recenzije (npr. *brown*, *auburn*...).
- *product_id*: Jedinstveni identifikator proizvoda na sajtu - veza ka *product_id* u *product_info*.



Skup podataka

Objašnjene kolone za reviews:

- *#*: Jedinstveni identifikator same recenzije unutar fajla.
- *product_name*: Pun naziv proizvoda - veza ka *product_name* u *product_info*.
- *brand_name*: Pun naziv brenda koji je napravio proizvod - veza ka *brand_name* u *product_info*.
- *price_usd*: Cena proizvoda u američkim dolarima - veza ka *price_usd* u *product_info*.



Primer prostiranja podataka kroz datoteke

reviews_<x>-<y>

#	author_id	rating	is_recommended	helpfulness	total_feedback_count	total_neg_feedback_count	total_pos_feedback_count	submission_time	review_text	review_title	skin_tone	eye_color	skin_type	hair_color	product_id	product_name	brand_name	price_usd
0	1945004256	5	1	0	2	2	0	12/10/2022	I absolutely L-O-V-E this oil...	A must have!	lightMedium	green	combination		P379064	Lotus Balancing & ...	Clarins	65

product_info

product_id	product_name	brand_id	brand_name	loves_count	rating	reviews	size	variation_type	variation_value	variation_desc	ingredients	price_usd	value_price_usd	sale_price_usd	limited_edition	new	online_only	...
P379064	Lotus Balancing & ...	2082	Clarins	8723	4.4029	139	1 oz	Size	1 oz		['(Hazel) Seed Oil, Flower Oil...]	65			0	0	0	...

product_info

...	out_of_stock	sephora_exclusive	highlights	primary_category	secondary_category	tertiary_category	child_count	child_max_price	child_min_price
...	0	0		Skincare	Moisturizers	Face Oils	0		



Predlog logičke šeme baze podataka

2. kolekcija: reviews

Polje	Tip podataka
#	String
author_id	String
rating	Number
is_recommended	Boolean
helpfulness	Number
total_feedback_count	Number
total_neg_feedback_count	Number
total_pos_feedback_count	Number

2. kolekcija: reviews

Polje	Tip podataka
submission_time	String
review_text	String
review_title	String
skin_tone	String
eye_color	String
skin_type	String
hair_color	String
product_id	String

1. kolekcija: product_info

Polje	Tip podataka
product_id	String
product_name	String
brand_id	String
brand_name	String
loves_count	Number
rating	Number
reviews	Number
size	String
variation_type	String
variation_value	String
variation_desc	String
price_usd	Number
ingredients	Array
value_price_usd	Number

1. kolekcija: product_info

Polje	Tip podataka
sale_price_usd	Number
limited_edition	Boolean
new	Boolean
online_only	Boolean
out_of_stock	Boolean
sephora_exclusive	Boolean
highlights	Array
primary_category	String
secondary_category	String
tertiary_category	String
child_count	Number
child_max_price	Number
child_min_price	Number



Upiti - analitičar kozmetičke industrije i trendova

Upit 1: Analiza hajpa i tagova - Da li proizvodi koji imaju tag 'Vegan' ili 'Clean + Planet Positive' u polju highlights imaju značajno višu prosečnu cenu i veći broj lajkova (loves_count) u odnosu na standardne proizvode?

Upit 2: Detekcija "Štetnih" sastojaka kroz kategorije - U kojim se sekundarnim kategorijama proizvoda najčešće pojavljuju neželjeni sastojci (npr. 'Alcohol', 'Paraben', 'Sulfate').

Upit 3: Strategija popusta - Koji brendovi najagresivnije koriste popuste (najveća razlika između price_usd i sale_price_usd) i da li su ti popusti rezervisani samo za *Limited Edition* proizvode?

Upit 4: Detekcija zasićenosti tržišta po varijacijama - Koji tipovi varijacija (variation_type npr. "Size", "Color/Tone") dominiraju u određenim sekundarnim kategorijama i koji brendovi kreiraju najkompleksnije proizvode (imaju najveći child_count, odnosno broj pod-varijacija)?

Upit 5: Hijerarhijska analiza cena - Kako se kreću cene (raspon min-max) kada se spustimo sa primary_category na secondary_category, pa na tertiary_category? (Pomaže u mapiranju najskupljih niša).



Predlozi upita - personalization data scientist

Upit 6: Proizvodi sa laznim marketingom - Pronalaženje proizvoda koji imaju ogroman hajp na sajtu (loves_count u vrhu), ali su u recenzijama dobili katastrofalne ocene od stvarnih kupaca (prosek ocena u recenzijama manji ili jednak 3.5). Može i obrnuto, mali broj lajkova, ali visoke recenzije.

Upit 7: Najbolje kreme za specifičan tip kože - Data Scientist pravi algoritam za preporuke. Koji brendovi imaju najbolji rejting isključivo među korisnicima koji imaju skin_type: 'Oily' i skin_tone: 'Light'?

Upit 8: Kritičari od poverenja - Želimo da izolujemo autore čije recenzije zajednica smatra izuzetno korisnim (helpfulness), a koji pišu detaljne opise (duže od 300 karaktera) i ne daju olako ocene 5.

Upit 9: Detekcija anomalija preporuka - Tražimo recenzije gde je korisnik dao loše ocene, 1 ili 2, a polje is_recommended je označeno sa 1 (preporučuje proizvod). Želimo da vidimo koji proizvodi imaju najviše ovakvih zbunjujućih recenzija.

Upit 10: Collaborative Filtering - Želimo da grupišemo recenzije prema potpunom profilu autora (skin_type + skin_tone + eye_color) i da izračunamo koji proizvodi imaju stopu preporuka (is_recommended) preko 90% unutar tog specifičnog mikrotipa.



Hvala na pažnji!